

VOICE DEEPFAKE

DSL 26-2 MODELING MULTIMODAL

15기 이세원 김재현 조유빈 16기 이혜원 최유성

CONTENTS

01. Introduction
02. data
03. model



INTRODUCTION

Chronology of the Crime

Autopsy Results



Research Team

Unsolved Crime

Incriminating evidence

Crime Scene

INTRODUCTION

PROBLEM

최신뉴스

"내 딸 납치?" 이 말 들은 지하철역 직원, 보이스피싱 막았다

쪽지를 통해 B씨의 남편 전화번호를 파악한 A씨는 남편을 통해 자녀가 안전한 상태임을 확인한 뒤 경찰에 신고했고, 금전 피해도 막을 수 있었다.

보이스피싱을 당할 뻔한 B씨는 "(AI를 활용해 변조된) 딸의 목소리를 듣고, 순간 앞이 캄캄해져서 무척 당황하고 두려웠는데, 다행히 역 직원의 도움으로 위기를 모면할 수 있었다"며 감사 인사를 전했다.

AI 음성 복제 피싱 주의보…"엄마 폰 고장" 50만원 노린다

박진종 기자 pjj@imaeil.com

매일신문 입력 2026-09-15 08:00:14

구글 검색 선

여기에 AI가 붙으면서 수법이 달라졌다. 금융감독원이 공개한 사례를 보면 딸의 목소리를 딥러닝으로 복제해 악성앱 링크를 보냈다. "액정이 깨져 통화가 어렵다"며 앱을 깔게 한 뒤 휴대폰을 원격 제어해 예금을 빼내는 방식이다. 경찰청도 자녀 목소리를 복제해 납치나 휴대폰 파손을 핑계로 긴급 송금을 요구하는 시도가 잇따르고 있다고 밝혔다.

요구 금액이 50만원 안팎인 것도 계산된 설계다. 의심하고 확인 전화를 돌리기보다 일단 보내고 마는 금액대를 노린다.

귀로 가려내는 것은 사실상 어렵다. 숭실대 AI보안연구센터 관계자는 올해 2월 "AI로 생성한 목소리는 운율이 자연스럽지 않거나 악센트가 다른 특징이 있지만 인간의 귀로 이를 감지하기는 어렵다"고 설명했다.

"얘야, 용돈 좀 보내" 엄마 목소리가 가짜?…설 명절 '딥보이스피싱' 경보

[뉴스웍스=박광하 기자] 설 연휴 기간 AI 기술을 악용해 목소리를 복제하는 보이스피싱 범죄가 급증할 것이라는 우려가 커지고 있다.

범죄자들은 단 2~5초의 짧은 음성 샘플만으로 특정인의 목소리를 정교하게 모방할 수 있는 딥러닝 기술을 활용해 가족이나 지인을 사칭하는 수법을 사용하고 있다.

국내에서는 기관 사칭형 보이스피싱이 지난해 1만3000여건으로 역대 최고치를 기록했으며, AI 음성 복제 기술이 결합하면서 더 큰 피해가 예상된다.

AI 음성 복제 기술을 뜻하는 딥보이스는 딥러닝과 목소리의 합성어로, 단 2~5초의 짧은 음성 데이터만으로도 특정인의 목소리를 85% 이상 정확도로 복제할 수 있다. 범죄자들은 이 기술을 악용해 피해자의 가족이나 지인의 목소리를 흉내내며 금전을 요구하는 수법을 사용하고 있다.

국내외에서는 이미 딥보이스피싱 피해 사례가 잇따르고 있다. 홍콩에서는 한 금융회사 직원이 화상회의에서 AI로 복제된 경영진의 목소리와 영상에 속아 2억5000만홍콩달러(약 430억원)를 송금하는 피해를 입었다. 영국에서는 에너지 기업 최고경영자(CEO)의 목소리를 복제한 사기범이 22만유로(약 3억2000만원)를 탈취한 사례가 발생한 바 있다.



DEMO

- LIVE RECORDING
- UPLOAD RECORDING

DATA

Chronology of the Crime

Autopsy Results



Research Team

Unsolved Crime

Incriminating evidence

Crime Scene

DATASET

9개 라벨 그룹의 구성

단독 4종, 음성·음악 혼합 4종, 잡음 1종을 하나의 체계로 관리한다.

그룹	VP	MP	VF	MF	FF	목표
실제 음성	1	0	0	-1	0	15%
가짜 음성	1	0	1	-1	1	15%
실제 음악	0	1	-1	0	0	15%
가짜 음악	0	1	-1	1	1	15%
실제 음성 + 실제 음악	1	1	0	0	0	9%
실제 음성 + 가짜 음악	1	1	0	1	1	9%
가짜 음성 + 실제 음악	1	1	1	0	1	9%
가짜 음성 + 가짜 음악	1	1	1	1	1	9%
잡음만	0	0	-1	-1	0	4%

VP / MP 성분 존재　　VF / MF 성분 진위　　-1 해당 없음

데이터셋 구성과 활용

8개 원천 데이터셋으로 실제·가짜 음성, 음악, 잡음을 구성

데이터셋	보유 데이터 / 이번 프로젝트의 선택 범위	활용 방식
ASVspoof 2019 LA	실제 발화와 합성·변조 음성	실제 음성 / 가짜 음성
Common Voice (한국어)	실제 사람이 녹음한 한국어 발화	실제 음성
MUSAN	실제 음성·음악·잡음, 보컬 포함 음악 원본 제외	실제 음성 / 실제 음악 / 잡음
FakeMusicCaps	음악 설명문을 바탕으로 생성한 음악	가짜 음악
VCTK	여러 화자가 녹음한 실제 영어 발화	실제 음성
DFADD	확산·Flow Matching 기반 TTS 생성 음성	가짜 음성
WaveFake	여러 음성 생성 모델로 만든 합성 음성	가짜 음성
SONICS	이번 프로젝트에서는 full fake 음원만 선택	가짜 음성 + 가짜 음악

SONICS는 음성·음악이 함께 있는 샘플을 투입 / MUSAN은 보컬 분리 대신 보컬 포함 원본을 제외

DATA PREPROCESSING

v1–v5 데이터셋 발전 과정

각 단계에서 발견한 문제를 다음 버전의 처리 정책에 반영했다.

v1
기본 구축

모든 잔여분 패딩

4개 출처 / 4종 혼합

28,000

최종 구성 샘플

v2
청크 정책 분기

짧은 꼬리 생성 방지

3가지 처리 정책

28,000

최종 구성 샘플

v3
구성·자동화

출처·라벨 비율 관리

7개 출처 / 9개 그룹

54,929

최종 구성 샘플

v4
라벨 품질 수정

보컬 포함 원본 제외

공평 배분 / SONICS

53,928

최종 구성 샘플

v5
잡음 조건 추가

일부 샘플 잡음 교체

라벨·전체 개수 유지

53,928

최종 구성 샘플

오디오 표준화

서로 다른 원천 오디오에 적용한 공통 입력·저장 규격

항목	표준화 설정
샘플레이트	16,000 Hz
채널	mono (모노)
청크 길이	10초 고정 = 160,000 샘플
저장 포맷	WAV, PCM_16
라우드니스 정규화	EBU R128 기준 · target LUFS = −23.0
피크 제한	peak ceiling = −1.0 dBFS

16,000 샘플/초 × 10초 = 청크당 160,000 샘플

DATA PREPROCESSING

10.2초 원본의 짧은 꼬리 처리

FakeMusicCaps에서 독립 샘플로 생성하던 약 0.2초 잔여분을 제거했다.



38,647
v1 청크

→

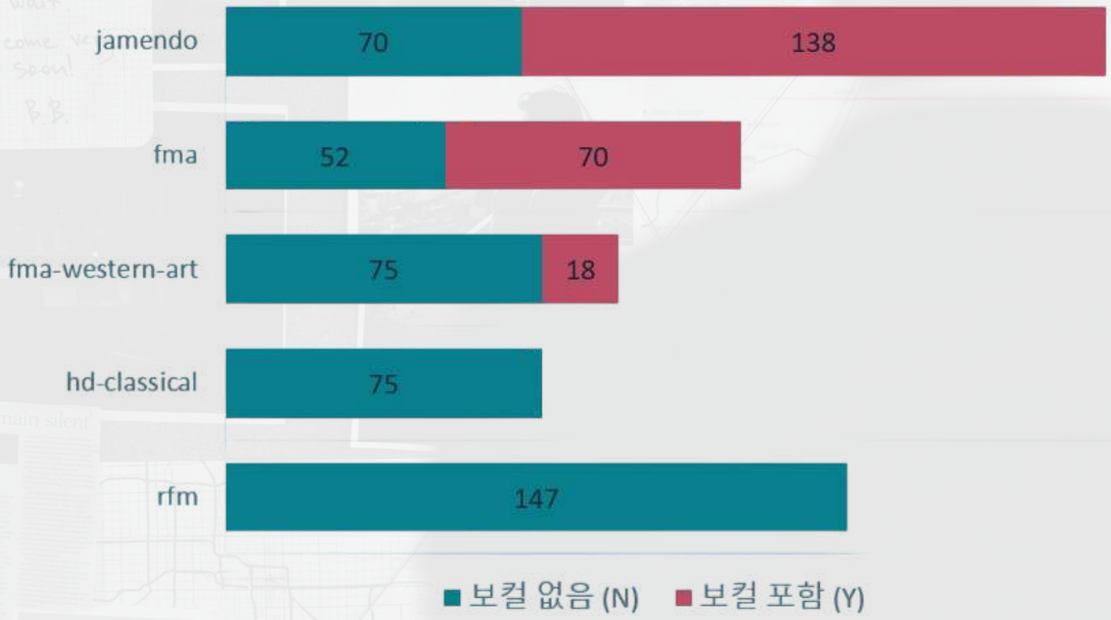
27,605
v2 청크

11,042개 감소

DATA PREPROCESSING

MUSAN music의 보컬 포함 원본 검증

공식 ANNOTATIONS를 대조해 순수 음악 pool의 출처를 다시 확인했다.



서브폴더 막대: 원본 파일 수 / 제외 규모: 파생 청크 수

5,958

청크 제외

v3 music 17,839개 중
보컬 포함 원본 유래
33.4%

DATA PREPROCESSING

v5는 전체 개수를 유지하며 잡음 조건을 추가

noise_only를 제외한 8개 그룹에서 약 25%를 잡음 처리 버전으로 교체했다.



12,955

전체의 24.0%

배경잡음 혼합

선택 샘플에 잔향을 50% 확률로 추가

VP / MP / VF / MF / FF 유지

FINAL DATASET

최종 v5 데이터셋 구성

총 53,928개 유지 · 아래 잡음 처리 샘플은 위 구성에 포함

그룹	음성 소스	음악 소스	train	val	test	합계
voice_only	ASV 20% / CV 30% / MUSAN 20% / VCTK 30%	—	6,666	832	832	8,330
voice_fake_only	ASV 40% / DFADD 40% / WaveFake 20%	—	6,664	833	833	8,330
music_only	—	MUSAN(보컬 제거) 100%	6,666	501	487	7,654
music_fake_only	—	FakeMusicCaps 100%	6,665	833	833	8,331
voice_music	실제 음성 비율 동일	MUSAN(보컬 제거)	4,000	300	293	4,593
voice_music_fake	실제 음성 비율 동일	FakeMusicCaps	4,000	500	500	5,000
voice_fake_music	가짜 음성 비율 동일	MUSAN(보컬 제거)	3,998	300	292	4,590
voice_fake_music_fake	가짜 음성 70% + SONICS 30%	FakeMusicCaps 70% + SONICS 30%	3,999	500	500	4,999
noise_only	—	MUSAN noise 100%	1,778	160	163	2,101

잡음 처리 현황

처리 수 / 전체 수 (비율)

12,955개

전체의 24.0% 교체

그룹	train	val	test
voice_only	1,666/6,666 (25.0%)	208/832 (25.0%)	208/832 (25.0%)
voice_fake_only	1,666/6,664 (25.0%)	208/833 (25.0%)	208/833 (25.0%)
music_only	1,666/6,666 (25.0%)	125/501 (25.0%)	122/487 (25.1%)
music_fake_only	1,666/6,665 (25.0%)	208/833 (25.0%)	208/833 (25.0%)
voice_music	1,000/4,000 (25.0%)	75/300 (25.0%)	73/293 (24.9%)
voice_music_fake	1,000/4,000 (25.0%)	125/500 (25.0%)	125/500 (25.0%)
voice_fake_music	1,000/3,998 (25.0%)	75/300 (25.0%)	73/292 (25.0%)
voice_fake_music_fake	1,000/3,999 (25.0%)	125/500 (25.0%)	125/500 (25.0%)
noise_only	0/1,778 (0%, 제외 대상)	0/160	0/163

MUSAN 보컬 제거: 보컬 포함 원본 제외. SONICS: 음성·음악이 함께 있는 샘플을 해당 그룹에 투입.

FINAL DATASET

원본 그룹 단위의 split 분리

여러 청크와 생성기 버전을 같은 split에 묶어 원본 중복 누출을 줄인다.

그룹 A	원본 A / 여러 청크	→	Train
그룹 B	원본 B / 생성기 버전	→	Validation
그룹 C	원본 C / 여러 청크	→	Test

기본 목표 80 : 10 : 10

비율보다 원본 그룹의 경계 유지가 우선

ASVspoof는 공식 분할 유지

LIMITATION

Aspect of DATA

-Fake Voice 대비 부족한 Fake Music 데이터셋 종류 다양성

-동일 gain 선형 혼합 → 실제 상대 레벨(SNR) 측정 및 0/5/10dB 비교

MODEL

Chronology of the Crime

Autopsy Results



Research Team

Unsolved Crime

Incriminating evidence

Crime Scene

MODEL STRUCTURE

0

오디오 파일

1

원본에서 음성/음악이 있을 확률 계산
(AudioMosaic)

2

오디오 파일에서 음성/음악 분리
(BSPolarFormer)

3

음성 FAKE 판별
(DF-Arena 1B, fine-tuned)

4

음악 FAKE 판별
(lofcz)

MODEL STRUCTURE

음성) DF-Arena 1B Fine-Tuning

V4 데이터 중 음성/음악 혼재된 오디오를 BSPolarFormer 사용해 음성과 음악 따로 분리

→ 분리된 음성 데이터를 통해 DF-Arena 1B Fine-Tuning

기존에 공개된 모델은 “BSPolarFormer을 거쳐 분리된 음성 데이터“를 본적이 없기 때문에 추가 학습이 성능을 향상시킨다!

MODEL STRUCTURE

음악) locfz 도입

여러 AI 음악 생성기를 통해 학습된 Artifactnet 대신 Suno, Udio 데이터로 학습된 lofcz 모델 도입 → 큰 폭의 리더보드 점수 개선

V3~V5 Train 데이터셋을 사용해 Fine-Tuning 시도했지만 성능 개선 없음
최종적으로는 공개된 lofcz 모델 가중치에 추가적인 Fine-Tuning X

+ 모델 학습 및 구조 업데이트 과정에서 V3~V5 데이터셋을 통해 Train, Validation 하며 성능 확인



THANK YOU FOR YOUR ATTENTION